Université Grenoble Alpes

Formalisme pour le TAL,

Représentation des connaissances :

Conception d'un moteur d'inférence pour une Grammaire Catégorielle du français

UFR LLASIC

Département d'Informatique intégrée en Langues, Lettres et Langage

2025 – 2026

Table des matières

1. INTRODUCTION : FORMALISME ET CADRE THÉORIQUE 3

2. PRINCIPES DE LA GRAMMAIRE CATÉGORIELLE (GC) 3

2.1. Catégories de bases et catégories fonctionnelles **4**

3. ARCHITECTURE DES CONNAISSANCE ET RAISONNEMENT SYMBOLIQUE 4

3.1. Partition du monde : KF et KP 4
3.2. Moteur d'inférence 5
3.3. Compréhension structurelle 5
3.4. Les six règles 5

4. DÉVELOPPEMENT ET TESTS SUR PHRASES SIMPLES 6

4.1. Implémentation 6
4.2. Difficultés d'implémentation 6
4.3. Lexique du corpus 7
4.4. Phrases analysées 7
4.5. Analyse des cas 8
4.6. Bilan des résultats sur phrases simples 12

5. APPLICATION SUR LANGUE RÉELLE : LE CAS DU GORAFI 13

5.1. Phrases retenues 13
5.2. Extension du lexique 13
5.3. Résultats et analyse 14
5.4. Comparaison phrases simples / Gorafi 15

6. POTENTIELS ET LIMITES 16

6.1. Points forts 16
6.2. Limites 17

7. PISTES D'AMÉLIORATION 17

8. SYNTHÈSE ET CONCLUSION 19

9. RÉFÉRENCES 19

1. Introduction : formalisme et cadre théorique

La modélisation syntaxique du langage naturel repose sur l'utilisation de formalisme, définit par Miller et Torris (1990) comme des systèmes de représentation abstraits permettant de décrire de manière explicite et rigoureuse les structures d'une langue. Dans cette perspective, le formalisme n'est pas seulement un outil de description, mais un métalangage qui sert d'interface entre la théorie linguistique et l'implémentation informatique.

L'objectif principal de ce travail est de concevoir et d'implémenter un moteur d'inférence capable de modéliser des structures syntaxiques du français à l'aide d'une Grammaire Catégorielle. Le système a été conçu pour répondre à plusieurs impératifs :

- *Lexique exhaustif* : construction d'une base de connaissance associant chaque entrée lexicale à ses catégories syntaxiques
- *Intégration des six méthodes de résolutions* : via les règles d'application (directe/inverse), de composition (harmonique/inverse), de *Type-Raising* ou montée catégorielle et de coordination
- *Exploration exhaustive* : l'algorithme doit explorer l'intégralité de l'espace de recherche pour une phrase donnée. Il ne doit pas se contenter de trouver une solution, mais il doit pouvoir rendre compte de toutes les dérivations possibles.
- *Modélisation des résultats* : génération d'une sortie HTML lisible et humainement interprétable, permettant une visualisation des arbres de dérivation et les décisions prises par l'automate.

Après une phase de test sur des phrases contrôlées (*ex*. « Garfield mange Mickey »), une autre partie de ce travail consiste à confronter le système face à la langue en usage réel. À cet effet, quelques phrases ont été extraites d'un article du Gorafi[1] , permettant d'explorer plus en détail les défis de la Grammaire Catégorielle face au français.

Ce travail se conclut par une analyse critique des résultats, visant à évaluer les potentiels, limites et axes d'amélioration du formalisme étudié.

2. Principes de la Grammaire Catégorielle (GC)

La Grammaire Catégorielle, contrairement aux approches traditionnelles qui multiplient les règles de réécriture, repose sur un formalisme lexicalisé. C'est-à-dire que chaque unité lexicale se voit attribuer une ou plusieurs catégories qui encodent à la fois sa nature et ses exigences combinatoires. La structure d'une phrase n'est donc pas imposée par des règles externes, mais par les contraintes combinatoires portées par les mots eux-mêmes.

[1] Lien article Gorafi : "Nicolas Sarkozy reçoit le prix de la littérature de la FIFA"

2.1. Catégories de bases et catégories fonctionnelles

Ce formalisme opère une distinction entre deux types de catégories :

- Les catégories de base : elles représentent les types fondamentaux, S (*Sentence* / Phrase) et NP (*Noun Phrase* / Groupe Nominal)
- Les catégories fonctionnelles : similaires à des fonctions recherchant des arguments pour produire un résultat. La directionnalité de cette recherche est définie par des « slashs » :
    - X / Y : recherche un argument de type Y sur sa droite pour produire un résultat X
    - X \ Y : recherche un argument de type Y sur sa gauche pour produire un résultat X

Par exemple en français, un verbe transitif comme « manger » peut recevoir la catégorie S \ NP / NP. Cela signifie qu'il cherche d'abord un NP (son objet) à sa droite pour devenir un S \ NP. Ce nouveau constituant cherchera ensuite un NP à sa gauche (son sujet) pour aboutir à la catégorie finale S.

3. Architecture des connaissance et raisonnement symbolique

L'implémentation de ce système repose sur une architecture de type KBS (*Knowledge-Based-System*), et est régi par le principe de déclarativité. Le savoir linguistique est énoncé explicitement et stocké sous une forme lisible tant pour l'humain que pour la machine. Cette structuration sous forme de catégories s'inscrit dans la tradition de la représentation des connaissances, dont l'Arbre de Porphyre constitue l'un des premiers modèles. En partitionnant le monde en classes strictes, nous imposons une hiérarchie rigide où chaque entité doit être classée pour être traitée. Cette approche garantit la transparence du système : chaque décision de la machine est traçable et explicable.

Il s'agit d'un raisonnement symbolique, où le système manipule des catégories formelles via des règles définies. Une approche différentes des modèles statistiques ou vectorielles de l'IA contemporaine par réseaux de neurones. Ce formalisme ne travaille pas sur des probabilités, mais sur la vérification de contraintes logiques.

3.1. Partition du monde : KF et KP

La base de connaissances se divise en deux entités distinctes :

- Les Connaissances Factuelles (KF) correspondent au lexique. C'est l'ensemble des assertions faites sur le monde linguistique que l'on a défini, répondant à la question : « Qu'est-ce que ce mot ? ». Dans une Grammaire Catégorielle, une entrée lexicale peut porter plusieurs catégories. Par exemple, le verbe manger peut être intransitif (S \ NP), transitif (S \ NP / NP), ou ditransitif (S \ NP / NP / NP).
- Les Connaissances Procédurales (KP) correspondent à la grammaire et encodent les mécanismes de combinaison. Ces règles fonctionnent sur un

mode de logique de type SI…ALORS…, sans possibilité d'ajouter un SINON. L'absence de règles applicables ne conduit pas à une approximation mais à un échec explicite, soulignant la binarité stricte du raisonnement. Une phrase est valide pour le système ou pas.

3.2. Moteur d'inférence

Le moteur d'inférence développé pour ce travail utilise donc les catégories lexicales (KF) pour appliquer les règles de combinaison (KP). L'objectif est d'arriver à réduire la phrase traitée jusqu'à obtenir (ou non) la catégorie cible S. Il se comporte ainsi comme un système à base de règles où chaque combinaison réussie est une inférence. L'arbre de dérivation final est une preuve formelle de la grammaticalité de la phrase.

3.3. Compréhension structurelle

L'une des implications majeures de ce raisonnement symbolique est sa capacité à valider la structure indépendamment du sens. À l'instar du poème de Lewis Carroll, *Jabberwocky* :

« '*Twas brillig, and the slithy toves*

Did gyre and gimble in the wabe »

Le système accepterait ces phrases même si certains mots sont « vides » sémantiquement, tant que ceux-ci respectent les contraintes combinatoires définies dans le lexique.

En somme, la Grammaire Catégorielle vérifie que les contraintes encodées dans le lexique sont satisfaites sans aucune compréhension du sens.

3.4. Les six règles

Les six règles implémentées sont les suivantes :

Règle	**Notation**	**Schéma formel**
Application	>	$X / Y \quad Y \rightarrow X$
Application inverse	<	$Y \quad X \setminus Y \rightarrow X$
Composition harmonique	>B	$X / Y \quad Y / Z \rightarrow X / Z$
Composition harmonique inverse	<B	$Y \setminus Z \quad X \setminus Y \rightarrow X \setminus Z$
Type Raising (TR)	T>	$NP \rightarrow S / (S \setminus NP)$
Coordination	<*>	$X \setminus X / X \rightarrow X$

4. Développement et tests sur phrases simples

4.1. Implémentation

Implémenté en Python, l'algorithme utilise un parcours en largeur pour remplir une table triangulaire indexée par les segments de la phrase. Le fonctionnement se déroule en trois phases :

- *Initialisation* : chaque token reçoit ses catégories lexicales issues du dictionnaire (*base_lexicale.txt ; lexique_gorafi.txt*). Le Type-Raising est également appliqué au NP de base.
- *Exploration* : pour chaque *span* de longueur croissante, tous les points de coupures sont explorés. Les 6 règles sont testées sur chaque paire de nœuds adjacents.
- *Traçabilité* : le programme garde en mémoire la trace de toutes les dérivations testées (succès, échecs et segments abandonnés prématurément). Ceci assure la transparence du processus et permet l'analyse critique.
- *Visualisation* : sortie en html, avec des arbres de dérivation facilitant la lecture humaine.

4.2. Difficultés d'implémentation

Le développement manuel a exposé plusieurs casse-têtes :

- Direction des slashs : la distinction entre / et \ impose de traiter les combinaisons dans le bons ordre, la moindre erreur de direction produisait des catégories incorrectes.
- La coordination : la gestion des X \ X / X n'est pas simple à traiter pour le moteur d'inférence, en raison du caractère polymorphe de l'étiquette, qui s'adapte au contexte.
- Sortie lisible : la représentation des arbres en html a demandé un travail important de mise en forme pour rendre les résultats humainement interprétables.
- Gestion des traces : afin d'analyser en profondeur les échecs et réussites, seulement cela augmente la charge de travail pour la machine.

4.3. Lexique du corpus

Entrée	Catégorie(s)	Description
Garfield, Mickey, Minnie, Jerry, Sylvestre	NP	Noms propres
chat, souris	NP	Noms commun
mange, manger, mangent, tue, dépiaute, attraper, dévore	S \ NP ; S \ NP / NP ; S \ NP / NP / NP	Verbes à valence multiple : intransitif, transitif, ditransitif
va, devrait	(S \ NP) / (S \ NP)	Auxiliaires modaux
voracement	S \ S	Adverbe
Le, la	NP / NP	Déterminants
et	X \ X / X	Conjonction de coordination
que	(NP \ NP) / (S / NP)	Pronom relatif objet

4.4. Phrases analysées

Le système a été testé sur des phrases simples créées. Le tableau suivant présente les résultats effectivement obtenus par le parseur :

N°	Phrase	Construction	S	Comb.	Temps	Mémoire
1	Garfield mange	Intransitif simple (S\NP)	2	6	0.52 ms	8.38 KB
2	Garfield mange Mickey	Transitif (S \ NP / NP)	3	22	0.61 ms	6.09 KB
3	Garfield mange Mickey et Minnie	Coordination d'objet (X \ X / X)	3	54	1.38 ms	13.27 KB
4	Le chat mange la souris	Déterminant + NP (NP / NP)	7	93	3.18 ms	19.97 KB
5	Garfield va manger Minnie	Auxiliaire modal ((S\NP)/(S\NP))	7	42	1.26 ms	13.96 KB
6	Garfield va attraper et devrait manger Minnie	Coordination + auxiliaires	20	153	2.01 ms	35.24 KB
7	Garfield mange voracement Mickey	Adverbe médian	0	26	0.85 ms	10.92 KB
8	Garfield mange Mickey voracement	Adverbe final	5	32	0.97 ms	9.25 KB
9	Garfield tue et Sylvestre dépiaute Jerry	Coordination de propositions complètes	7	92	2.48 ms	18.33 KB
10	Mickey que Garfield dévore	Relative objet	0	15	1.41 ms	11.65 KB
11	Mickey et Jerry que Garfield dévore mangent voracement	Phrase complexe : Relative + coordination + adv	14	138	3.47 ms	29.46 KB

Légende : S : aboutissant à S ; Comb. : Nombre de paires testées

4.5. Analyse des cas

A. Structures de base

Garfield mange (P1)

Succès immédiat. La simplicité de la dérivation limite le nombre de combinaisons, les variations proviennent quasi exclusivement de l'application du Type-Raising.

Garfield mange Mickey (P2)

Dérivation principale :

- Mange : S \ NP / NP
- Combinaison avec Mickey → S \ NP
- Combinaison avec Garfield → S

Dérivation alternative :

- TR de Garfield
- Application indirecte via composition

On remarque que les dérivations atteintes ne modifient pas le résultat final, on arrive à la même interprétation sémantique mais cela augmente artificiellement le nombre d'analyses.

Le chat mange la souris (P4)

Techniquement c'est la même structure que la phrase P2, mais on arrive à 93 combinaisons, dont 7 valides, contre 22 pour la P2. Une possible explication est la présence des déterminants (NP / NP), ceux-ci ajoutent une couche de combinatoire supplémentaire, illustrant l'impact direct du lexique sur la charge du moteur d'inférence.

De même, l'impact temporel (0.61 ms vs 3.18 ms) et sur la mémoire (6.09 KB vs 19.97 KB) augmente

Garfield va manger Minnie (P5)

Pour un énoncé de seulement quatre mots, le système explore 42 combinaisons. Un chiffre élevé, pour une phrase de quatre mots. Cela s'explique par la coexistence de deux stratégies :

1- *Application directe puis composition* :

va *(S \ NP) / (S \ NP)* + manger *S \ NP/ NP* → *S \ NP / NP* via la règle >B

S \ NP / NP + Minnie *NP* → *S \ NP* via la règle **>**

Garfield *NP* + *S \ NP* → *S* via la règle **<**

2- *Type-Raising* :

Garfield *NP* → *S / S \ NP* via la règle T>

Puis composition successive avec *va manger Minnie* jusqu'à S

Cette phrase démontre un premier écart entre la rigueur du formalise et la réalité du langage. En effet, le système identifie sept dérivations valides aboutissant à l'axiome S, que l'on peut regrouper en cinq schémas de parenthésage distincts :

Schéma	Structure de parenthésage	Dérivations associées	Évaluation humaine
I	(Garfield ((va manger) Minnie))	2 et 4	Interprétation peu cohérente
II	(Garfield (va (manger Minnie)))	1 et 3	Interprétation cohérente
III	((Garfield (va manger)) Minnie)	6	Interprétation fragmentée
IV	(((Garfield va) manger) Minnie)	7	Incohérente
V	((Garfield va) (manger Minnie))	5	Incohérente

Ces schémas montrent trois problématiques :

Redondance : comme mentionné plus haut, l'application du Type-Raising engendre une prolifération des dérivations. Pour la machine elles sont distinctes mais pour l'humain c'est sémantiquement équivalents.

Unification prématurée (Schéma III) : le système permet l'union précoce du sujet et de l'auxiliaire. Cela crée un constituant instable qui pourrait être interprété comme une phrase complète par erreur, risquant de fausser la hiérarchie des dépendances logiques.

Surgénération : les schémas IV et V, bien que syntaxiquement valides selon les règles de la Grammaires Catégorielle, ne sont pas cohérents pour l'interprétation humaine. Notre système génère donc du bruit.

B. Coordination et ambiguïté

Garfield mange Mickey et Minnie (P3)

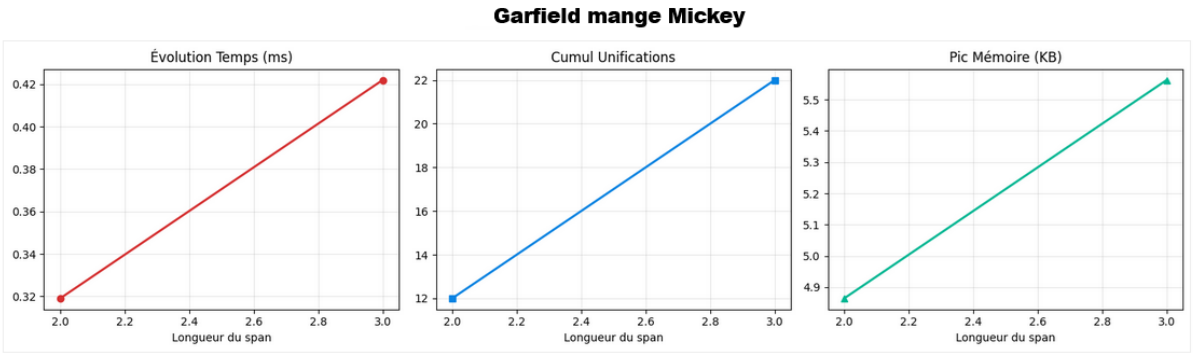
La coordination introduit une ambiguïté structurelle avec la catégorie polymorphe X\X/X (où X peut être n'importe quelle catégorie). Deux stratégies principales coexistent :

- Coordination du groupe nominal (Mickey et Minnie) avant de l'intégrer au verbe
- Variations dans l'ordre des combinaisons : exploration de plusieurs chemins multipliant les arbres de dérivation possibles pour une même lecture. (Comme pour la P2)

Garfield va attraper et devrait manger Minnie (P6)

Cette phrase représente un point de complexité. Elle mobilise simultanément des auxiliaires modaux, une coordination de syntagmes complexes et une transitivité directe. Sa résolution suit trois étapes :

- Identification des blocs complexes « *va attraper* » et « *devrait manger* » (>B)
- Coordination (<*>)
- Phrase finale en S



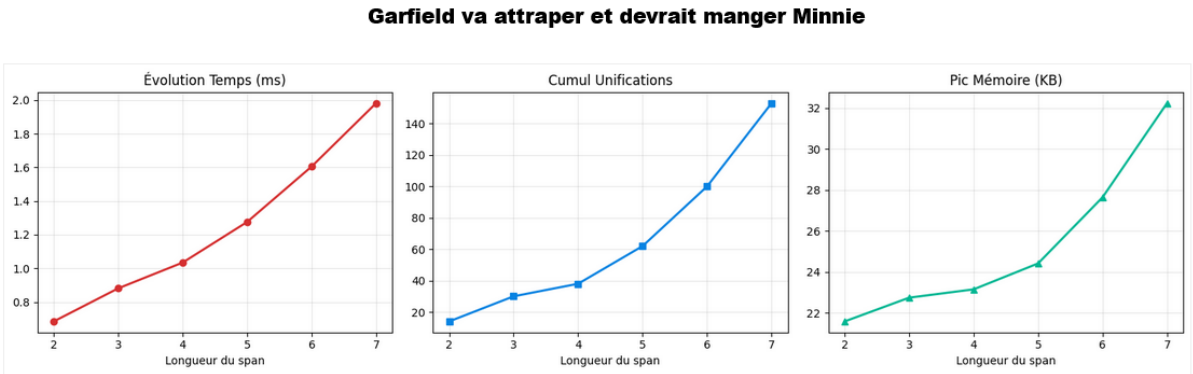


Figure 1 – Analyse comparative des coûts (P2 vs P6)

Avec 20 analyses aboutissant à S et un total de 153 combinaisons testées, cette phrase P6 illustre le phénomène d'explosion combinatoire. L'observation de la Figure 1 met en évidence cette escalade des coûts :

Explosion des unifications : alors que la phrase n'a que doublé (3 vs 7 tokens), le nombre de paires testées a été multiplié par sept. Chaque nouveau mot complexe (auxiliaire, coordination) crée une multitude de nouveaux chemins de dérivations possibles.

Temps : la courbe d'évolution du temps suit celle des unifications.

Mémoire : le stockage de la trace de chaque dérivation devient coûteux, surtout que le système génère du bruit avec 20 analyses finales, dont beaucoup sont redondantes, multipliant la charge sur la RAM.

Ces résultats montrent que la complexité d'une phrase en Grammaire Catégorielle ne se mesure pas à son nombre de mots mais à la charge combinatoire que chaque catégorie encodée impose au moteur d'inférence.

Garfield tue et Sylvestre dépiaute Jerry (P9)

Cette phrase représente un des cas complexes de notre travail où le moteur doit tester plusieurs hypothèse avant d'identifier la ou les structures correctes.

Le stockage des différents états en mémoire s'intensifie, illustrant un de performance du système sur des phrases nécessitant beaucoup de règles combinatoires.

C. Adverbe : limite de la partition du monde

Garfield mange voracement Mickey (P7) et **Garfield mange Mickey voracement** (P8)

L'analyse de ces phrases révèle les limites de notre modélisation actuelle. La définition des adverbes comme étant S \ S, c'est-à-dire qu'il attend une phrase à sa gauche pour produire une phrase, provoque une impasse dès lors que l'adverbe est placé en position médiane (P7), mais fonctionne parfaitement si l'adverbe est en position finale.

C'est ici que la dérivation bloque :

- *mange* (S \ NP / NP) + *voracement* (S \ S) → échec : les types ne sont pas compatibles
- *voracement* (S \ S) + Mickey (NP) → échec : aucune règle ne marche ici

Ces combinaisons sont impossible d'après nos connaissances actuelles. Cet échec illustre la binarité du système symbolique. S'il manque une étiquette dans le lexique ou si une règle de combinaisons n'est pas prévue, le moteur d'inférence arrête son parcours. Ce blocage démontre que pour traiter le langage naturel le lexique doit être le plus exhaustif possible.

D. Structures complexes et relatives

Mickey que Garfield dévore (P10)

Le système produit un NP final et non un S. C'est un résultat linguistiquement correct, en effet, c'est un groupe nominal avec une relative donc une phrase « incomplète » sans verbe principal. Cependant, notre définition d'une phrase valide impose le S comme seule catégorie valide, et donc le NP final est rejeté. Le rejet ne traduit pas un

défaut de dérivation, mais illustre la cohérence interne du système avec sa propre définition. C'est d'ailleurs l'exemple le plus probant de la binarité du raisonnement symbolique : la dérivation est juste, le résultat est rejeté non par erreur mais parce qu'il ne correspond pas à l'axiome cible. Le moteur reste fidèle à sa vérité.

Mickey et Jerry que Garfield dévore mangent voracement (P11)

Cette phrase a mobilisé 5 des 6 règles implémentées.

L'adverbe en position finale ne pose aucun problème, c'est le même mécanisme qui réussit en P8. Son succès confirme que l'impasse en P7 est bien due à la position médiane de l'adverbe et non à sa catégorie. Ce résultat valide que la relative objet fonctionne dans une phrase complète.

4.6. Bilan des résultats sur phrases simples

Le système démontre une bonne capacité à traiter des structures simples (SVO) comme des configurations plus complexes (coordinations, relatives). Les réussites de dérivations sur les phrase P9 et P11 montrent la force du couple *type-raising* / composition harmonique. Ces deux règles permettent de capturer des phénomènes linguistiques étendus, tels que les relatives objets.

Le principal problème identifié est la surgénération, déjà observée en P5 : l'application *du type-raising* à chaque NP impacte directement la charge mémoire et le temps de calcul. L'analyse de la phrase P6 explicite ce phénomène, avec 153 combinaisons testées, elle démontre que l'explosion combinatoire n'est pas corrélée à la simple longueur de la phrase, mais à la charge combinatoire. De plus en conservant en mémoire absolument tous les états explorés, la machine subit une accumulation de données ce qui rend le traitement de structures denses (auxiliaire, coordination) coûteux.

Au-delà du coût en ressources, cette surgénération produit des véritables bruits syntaxiques. Comme le montre les schémas IV et V (voir section 4.5), le système valide des structures qui, bien que conforment aux règles de la Grammaire Catégorielle, sont incohérentes pour une interprétation humaine. Le système produit ainsi des sorties qui ne correspondent à aucune réalité sémantique.

Les échecs rencontrés ont deux causes distinctes. L'impasse sur P7 (adverbe médian) relève d'une lacune lexicale, l'adverbe ne peut se rattacher que sur une phrase. En revanche, le rejet de P10 (relative objet) n'est pas dû au lexique, la bonne dérivation se construit correctement, mais à la définition stricte de l'axiome cible. En effet, le moteur à pour instruction de valider uniquement les séquences aboutissant à S, et le NP produit ne satisfait pas ce critère.

Le cas de P10 montre que l'intelligence du système ne réside pas seulement dans ses règles de calcul, mais dans la finesse de la partition du monde opéré. Le moteur reste fidèle à sa vérité, son comportement est donc entièrement dicté par les catégories

définies et les objectifs fixés. En somme, le système vérifie la conformité d'une entrée vis-à-vis d'un modèle du monde prédéfini.

Tous les arbres de dérivations sont disponibles dans le fichier *sortie_CGC_simple.html*

5. Application sur langue réelle : le cas du Gorafi

Afin d'aller plus loin que de simples phrases construites, quelques phrases ont été extraites d'un article du Gorafi. Ce test permet de confronter le système à la langue en usage réel et notamment sur des structures absentes des phrases précédentes.

5.1. Phrases retenues

Les trois phrases soumises au programmes sont les suivantes :

- P1 : Nicolas Sarkozy reçoit le prix de littérature de la FIFA.
- P2 : Un immense honneur et une grande fierté après tant de jours de souffrance.
- P3 : Cette cérémonie intervient une semaine à peine après la remise du prix de la paix de la FIFA à Donald Trump.

5.2. Extension du lexique

Pour traiter ces nouvelles phrases , il a fallu étendre le lexique et notamment intégrer de nouvelles catégories : prépositions, noms propres composés et adjectifs. Les propositions retenues sont les suivantes :

- Noms de famille (NP \ NP) : traités comme modifieurs de NP (*ex*. Sarkozy modifie Nicolas par la gauche)
- Adjectifs antéposés (NP / NP) : l'adjectif cherche un NP à sa droite pour produire un NP
- Prépositions (NP \ NP / NP) : la préposition cherche d'abord un NP à sa droite (son complément) pour devenir un NP \ NP. Celui-ci cherche ensuite un NP à sa gauche (tête nominale) pour produire un NP

Note : Le choix a été fait d'exclure la ponctuation pour cet essai. Son traitement constituerait un défi majeur dépassant le cadre de ce travail.

Entrée	**Catégorie**
Nicolas, Sarkozy	NP, NP \ NP
Donald, Trump	NP, NP \ NP
reçoit	S \ NP / NP
intervient	S \ NP
le, la, une, cette	NP / NP
Un, immense, grande	NP / NP
de, à, après, du	NP \ NP / NP
prix, littérature, FIFA, honneur, fierté, cérémonie, semaine, remise, paix	NP
tant	S / S

et	X \ X / X

5.3. Résultats et analyse

N°	Phrase	Construction	S	Comb.	Temps	Mémoire
1b	Nicolas Sarkozy reçoit le prix de la littérature de la FIFA	Structure SVO + complément d'objet	106	518	12.27 ms	125.17 KB
2b	Un immense honneur et une grande fierté après tant de jours de souffrance	Structure averbale	0	135	21.48 ms	69. 27 KB
3b	Cette cérémonie intervient une semaine à peine après la remise du prix de la paix de la FIFA à Donald Trump	Enchâssement de préposition	0	107 036	1636.11 ms	12 823.91 KB

Nicolas Sarkozy reçoit le prix de la littérature de la FIFA (P1b)

La phrase suit un structure SVO classique et est intégralement analysée. Cependant, elle génère une explosion de combinaisons, surtout due à la définition des prépositions en NP \ NP / NP et des noms de famille en NP \ NP.

Avec cette multiplication des types NP, chaque préposition peut s'attacher à différents antécédents, multipliant les arbres possibles. Cela se ressent sur la charge de travail : 518 combinaisons, 12.27 ms, 125.17 KB. À titre de comparaison, la phrase P11 des tests précédents (*Mickey et Jerry que Garfield dévore mangent voracement*), de longueur quasi-similaire, produisait 138 combinaisons en 3.47 ms pour 29.46 KB. Cela confirme que la complexité est davantage liée à la densité du lexique et aux combinaisons qu'à la longueur de la phrase. Un lexique plus étendu, couvrant plus de catégories grammaticales fait indéniablement grimper les coûts.

Enfin l'obtention de 106 dérivations valides, confirme le problème de la surgénération déjà identifié sur les phrases précédentes. Le système s'époumone à prouver 106 fois une validité, avec des chemins différents

Un immense honneur et une grande fierté après tant de jours de souffrance (P2b)

Cette phrase a été choisie pour son caractère averbal. Elle accumule des NP sans verbe. Notre système aboutit fatalement à un échec (0 dérivations valides). Toutefois, cet échec est cohérent avec la partition du monde établie. Notre système définit une

phrase valide par l'obtention d'un S en axiome, lequel suppose dans notre grammaire, la présence d'un prédicat verbal.

Exactement comme pour la relative objet P10 des phrases avec Garfield, cet échec s'inscrit dans la définition même de notre vérité. Ce n'est pas un bug, c'est la même cohérence interne que celle observée sur P10, appliquée ici à une structure averbale. Il démontre ainsi la capacité à rejeter des structures qui ne correspondent pas au modèle préétabli.

Cette cérémonie intervient une semaine à peine après la remise du prix de la paix de la FIFA à Donald Trump (P3b)

Ce cas d'étude fut un échec critique et illustre la limite du traitement symbolique exhaustif face à la complexité de la langue réelle. Sans même produire de résultat, le programme a exploré 107 036 combinaisons en 1636 ms pour une consommation mémoire de 12 823 KB.

La machine ayant eu du mal à suivre, stoppe prématurément la recherche. En explorant la trace des erreurs, le plantage intervient au moment de la récupération des arbres de dérivations avant de l'intégrer dans le fichier HTML. La cause est purement matérielle avec une saturation de la RAM.

Ces chiffres illustrent de façon concrète l'explosion combinatoire. Avec l'enchâssement de plusieurs syntagmes prépositionnels et un lexique dense cela démultiplie l'espace de recherche. Sans mécanisme de contrôle, la RAM n'arrive pas à absorber ce type de structure provoquant un plantage système.

En raison du coût en ressources, la phrase a été retirée des visualisations dans le fichier *sortie_gorafi.html.* Son inclusion provoquait des ralentissements majeurs et des difficultés de lecture pour le navigateur.[2]

5.4. Comparaison phrases simples / Gorafi

	Corpus Garfield	**Corpus Gorafi**
Arrive	SVO, coordination, modaux	SVO avec prépositions simples
Difficultés	Adverbe médian, relative	Phrases averbales, enchâssement
Temps moyen	< 0,2 ms par phrase	Jusqu'à plusieurs secondes
Combinaison	6 à 153 selon la longueur de la phrase et définition du monde	107 036

L'écart observé entre les deux tests ne s'explique pas uniquement par la longueur des phrases. Le point crucial observé concerne la densité catégorielle du lexique Gorafi.

2 Le fichier brut complet, incluant cette dérivation malgré sa complexité, est disponible dans le rendu sous le nom sortie_gorafi_complet.html

En effet, l'ajout des préposions, des noms de familles et des adjectifs démultiplient les catégories disponibles à chaque cas, amplifiant par la même occasion l'explosion combinatoire.

Cette richesse lexicale amplifie l'explosion combinatoire en offrant au moteur un nombre exponentiel de chemins de dérivation à explorer. Cet essai sur un article du Gorafi expose la vulnérabilité du formalisme face à la saturation des informations présentes dans la langue réelle.

6. Potentiels et limites

6.1. Points forts

Explicabilité et traçabilité totales

Contrairement aux réseaux de neurones, chaque décision du moteur est justifiée pas à pas. On peut voir les succès, les échecs et les derniers segments avant abandon. L'arbre de dérivation est une preuve formelle et pas un résultat opaque. Cette transparence est précieuse pour l'explicabilité.

Le lexique portant la grammaire

Toutes les informations grammaticales sont entièrement portées par le lexique, plutôt que dispersées dans des règles. Cela permet d'avoir une grammaire très adaptable au domaine.

Modularité

La séparation entre connaissances (KF et KP) et le moteur d'inférence permet d'enrichir ou de modifier le lexique facilement sans changer le moteur. C'est exactement ce qu'il s'est passé lors du passage des phrases construites à celles du Gorafi, l'ajout dans le lexique de nouveaux éléments a permis de traiter un nouveau type de phrase sans modifier le code.

Universalité des règles

Six règles ont suffi à couvrir un large éventail de constructions syntaxiques. Elles s'appliquent uniformément, sans cas particuliers codés en dur, permettant une certaine généralisation.

Gestion des structures complexes

Le combo *type-raising* et composition harmonique permet de traiter des phénomènes linguistiques étendus, des relatives objets à la coordination de groupes complexes. Tout ceci en gardant un formalisme minimal.

6.2. Limites

La surgénération

Sans garde-fou, la surgénération observée dès les premières phrases simples, s'amplifie avec la longueur de la densité lexicale. Polluant les résultats et saturant inutilement les ressources.

La rigidité de la partition du monde

Pour la machine notre monde est binaire. Tout tourne autour du verbe, une phrase est valide (S) si elle a un prédicat verbal. De ce fait, les phrases averbale sont fatalement exclues même si elles font sens pour un humain.

La taille du lexique et complexité du développement

Chaque mot doit être enregistré manuellement avec toutes ses catégories possibles. Or en français, entre la multitude des déclinaisons verbales, la position des adjectifs ou la gestion des clitiques, l'exhaustivité est difficilement atteignable sans augmenter les coûts ailleurs. Si ce travail est pénible à mettre en place pour un article, il devient irréaliste pour des corpus massifs comme Wikipédia, du moins en l'état.

La ponctuation

La ponctuation a été délibérément exclue de cet essai. Il n'y a pas de mention de son traitement dans le formalisme. Or, dans un texte réel, les signes de ponctuation ne peuvent simplement pas être ignorés.

La charge mémoire

Le système mis en place pour ce travail conserve l'intégralité des états explorés. Sur des phrases longues avec un lexique dense, la mémoire finit par saturer et la machine ne peut plus suivre. La phrase P3 du Gorafi en est un parfait exemple.

Les langues à ordre « souple » ou libre

Avec les quelques exemples exploré dans ce travail, on remarque vite que les phrases aux structures SVO s'en sortent bien. Ce formalisme a dû être développé sur des langues à ordre rigide comme l'anglais. Son application sur du français montre déjà des limites assez conséquentes, mais essayer de faire la même chose sur des langues à ordre libre, comme le latin ou russe, où l'information grammaticale est portée par des flexions doit être un défi de taille, voir quasi impossible, sans ajout d'autre couches de traitement.

7. Pistes d'amélioration

Plusieurs axes d'optimisation peuvent être envisagés.

Restriction du Type-Raising

Dans l'implémentation actuelle, le *type-raising* est déclenché dès qu'un NP est détecté dans une phrase. Cela y compris dans des constructions simples, comme la phrase

P1, où il n'est pas nécessaire. Cette application systématique génère des dérivations supplémentaires, polluant les résultats et consommant des ressources inutilement. Il faudrait le restreindre aux contextes où il est réellement utile à la dérivation. Par exemple si une relative objet est détectée, car c'est dans cette situation qu'il est indispensable pour construire le S / NP dont *que* a besoin. Cela permettrait de réduire la surgénération sans perdre de couverture.

Fusion des analyses similaires

En associant des représentations sémantiques aux règles de combinaison, il deviendrait possible de détecter les dérivations produisant le même sens et de les fusionner. Cela permettrait de ne conserver qu'une dérivation par interprétation sémantique. Le système gagnerait ainsi en lisibilité et en efficacité, sans sacrifier sa couverture syntaxique.

Prétraitement des textes

Lemmatisation

Pour une application sur le français, il serait intéressant de lemmatiser le texte préalablement. Une seule entrée pour *manger* couvrirait *mange*, *mangent*, *mangé*, etc., réduisant donc la taille du lexique.

Segmentation / Chunking

Une étape de segmentation en chunks permettrait de réduire la longueur effective des séquences analysées en regroupant les syntagmes simples. On diminue l'espace de recherche et limite l'explosion combinatoire sur phrases longues comme pour la P3b du Gorafi.

Probabilités

L'ajout de probabilités aux catégories lexicales avant l'analyse permettrait d'enlever les catégories peu probables dès le départ, évitant ainsi des calculs inutiles.

Pondération des règles

Attribuer un poids aux règles de combinaison serait une solution pour aiguiller le moteur vers les dérivations plus canoniques, sans pour autant effacer les autres. Cette approche permettrait de mieux maîtriser la combinatoire sans tirer un trait sur le cœur du formalisme.

Lexique par domaine d'application

Plutôt que de viser un lexique général et exhaustif, difficilement tenable pour toutes les langues du monde, une piste serait de construire des ensembles lexicaux spécialisés par domaine. Un même mot peut relever de catégories différentes selon le contexte. Par exemple, *conclure* est presque toujours utilisé avec un complément dans le langage courant, mais dans le domaine juridique c'est un verbe strictement intransitif.

8. Synthèse et conclusion

Ce travail avait pour objectif de concevoir, d'implémenter un moteur capable de modéliser des structures syntaxiques du français à partir d'une Grammaire Catégorielle.

Le bilan est celui d'un outil théoriquement solide et pédagogiquement éclairant. Mais dont, le passage sur des textes réels met en évidences des problèmes d'applications importants.

Sur le plan de la représentation des connaissances, le système illustre concrètement les principes de déclarativité, avec la base de faits (KF) et la base de règles (KP). Ces deux composantes constituent une architecture transparente où chaque décision de la machine est visible et traçable. On peut voir pourquoi une phrase est acceptée ou rejetée, et c'est une valeur en soi. Une approche bien différente des réseaux de neurones actuels, dont les représentations internes restent opaques.

Sur le plan linguistique, six règles suffisent à couvrir un large éventail de construction du français avec de bonnes performances sur phrases courtes. Le principal obstacle identifié est la surgénération, notamment avec le *type-raising* non guidé.

L'application sur les phrases du Gorafi révèle l'écart entre la langue contrôlée et la langue en usage réel. Tout part de la définition de la vérité posée au départ : qu'est-ce qu'une phrase ? Qu'est-ce qu'un mot ? Le choix de la partition est à la fois la force du système (rigueur, traçabilité, explicabilité), mais aussi sa principale limite (rigidité, explosion combinatoire).

A partir de ce travail, on peut venir greffer des enrichissements afin de le rendre plus exploitable : rajout d'informations sémantiques, probabilités, lemmatisation, chunking, etc.

La grammaire catégorielle, dans sa compacité et sa rigueur, reste un formalisme fécond pour penser l'interface entre structures linguistiques et traitement automatique.

9. Références

Miller, P. & Torris, T. (1990). Formalismes syntaxiques pour le traitement automatique du langage naturel. Hermès.

Steedman, M. & Baldridge, J. (2011). Combinatory Categorial Grammar. In R. Borsley & K. Börjars (eds.), Non-Transformational Syntax. Wiley-Blackwell.